

Orquestando códigos

La sinfonía de los sistemas

Arquitectura de microservicios en la nube
para una plataforma de boletería

Juan Esteban Vélez Venegas

Arquitectura de Software · Unidad 1 · Actividad 2

Caso: Armonía S.A.S.

El problema no es el código


Armonía S.A.S. — boletería colombiana. 1,8 millones de boletas en 2025.
Monolito PHP, una base de datos, dos servidores.

Fecha	Incidente	Impacto
Mar 2025	Caída de 47 min en un <i>onsale</i>	1 900 M COP perdidos
Jun 2025	Doble cobro a 3 200 clientes	340 M COP + sanción
Ago 2025	Sobreventa de 180 boletas	Reubicaciones
Nov 2025	Cae el correo → cae la venta	6 h sin operar
Ene 2026	Despliegue de reportes tumba la venta	2 h sin operar

Cinco síntomas. **Una sola causa: todo está acoplado a todo.**

Lo que hace único a este negocio

La demanda no es una curva. Es un pico.



- Del minuto 0 al minuto 1: **de 200 a 100 000 usuarios**
- El resto del mes: prácticamente ocioso
- Presupuesto: **$\leq 8\,000$ USD/mes**, y debe **bajar** fuera del pico

Escalar el monolito = pagar el pico todo el mes.

La bisagra del trabajo

Cada decisión responde a un requisito. Ninguna a una moda.

Requisito	Decisión arquitectónica
RNF-03 · 100 000 usuarios en 60 s	Microservicios + autoescalado independiente
RNF-09 · Sobreventa = 0	Bloqueo optimista con número de versión
RNF-10 · 1 cobro por N reintentos	Receptor idempotente en 2 niveles
RNF-06 · La caída externa degrada, no apaga	Circuit Breaker + Retry + Bulkhead
RF-07 · No hay transacción ACID distribuida	Saga orquestada con compensación
RNF-01 · Lecturas masivas	Cache-Aside + CQRS
RNF-11 · Desplegar sin detener la venta	Base de datos por servicio

13 requisitos funcionales · 16 no funcionales · 30 patrones

Lo que se evaluó y se descartó

Opción	Por qué no
Monolito modular	Obliga a replicar <i>todo</i> para un pico que afecta al 20 % del código. ×5 el costo
Serverless puro	Arranque en frío justo en el minuto del <i>onsale</i> ; ata la saga a un orquestador propietario
Commit en 2 fases	Bloquea recursos, y la pasarela externa no implementa el protocolo
Saga coreografiada	Nadie puede responder «¿en qué paso va esta compra?»
Service Mesh	Exige equipo de plataforma dedicado (el equipo es de 9 personas)

Documentar lo que **no** se usó demuestra que hubo decisión, no acumulación.

Arquitectura: vista general






Diagrama de casos de uso



Tres decisiones salen de aquí: lo que cruza la frontera necesita resiliencia · **extend** hacia *Compensar* justifica la saga · el **reloj** como actor exige un proceso en segundo plano.


Diagrama de clases



version en **LineaDeInventario** **no es persistencia: es lo que impide la sobreventa.**


Añadir una pasarela o una tarifa = **una hoja nueva, cero clases modificadas.**

Secuencia: la compra funciona




La espera del comprador termina en el paso 10. Notificaciones y proyección ocurren después: el correo no está en el camino crítico.

Secuencia: la compra falla



Retry absorbe lo transitorio → el cortacircuitos corta lo persistente →
la compensación deja el inventario idéntico.

Diagrama de despliegue



Réplicas distintas por servicio · **ninguna flecha** entre un servicio y la BD de otro ·
la subred de datos no ve Internet.

Patrón 1 · Saga orquestada

El problema

Una compra cambia **dos servicios**. Sin monolito, no hay transacción ACID.

Por qué no *commit* en dos fases

Bloquea recursos con 100 000 usuarios. Y sobre todo:

la pasarela externa no implementa el protocolo.

Por qué orquestada y no coreografiada

Coreografiada es más desacoplada, pero la lógica queda repartida.

Para un flujo de dinero, la trazabilidad vale más que el desacople.

Lo que cuesta

Ventanas de inconsistencia. Hay que diseñar una compensación por cada paso.

Con la pasarela caída, el tiempo de respuesta pasó de

711 ms → 1 ms

Esa es la diferencia entre degradarse y caerse.

Patrón 2 · Circuit Breaker (y sus tres compañeros)

```
Mamparo → Cortacircuitos → Reintento → Tiempo límite → red
(aísla)   (falla rápido)   (absorbe transitorios) (nunca espera indefinidamente)
```

El orden no es arbitrario: el tiempo límite se aplica a *cada* intento; el reintento responde a que uno expiró; el cortacircuitos dice «*ni siquiera lo intentes*».

Dos sutilezas que casi nadie implementa

1. **Distingue infraestructura de negocio.** Un `409 sin cupo` significa que el servicio está **sano**. Contarlo abriría el circuito sin motivo.
2. **Es por ruta, no por servicio.** Cae la pasarela → se corta la compra, **pero la consulta de reservas sigue viva.**

Patrón 3 · Receptor idempotente

El incidente de junio: 3 200 clientes cobrados dos veces

La petición llega, la respuesta se pierde, el cliente reintenta.

El problema no es del cliente: el servidor no distingue nueva de repetida.

Nivel	Clave	Protege contra
Cliente → reservas	<code>idempotency-key</code> del cliente	El usuario reintentando
Reservas → pagos	<code>cobro-{idReserva}</code>	El propio Retry reintentando

El segundo nivel es el que se olvida:

el patrón Retry es en sí mismo una fuente de duplicados.

```
1er envío → HTTP 201, reserva RES-C37E67BD
2do envío → HTTP 200, reserva RES-C37E67BD ← la misma. Un solo cobro.
```

Patrón 4 · Bloqueo optimista

El incidente de agosto: 180 boletas sobrevendidas

Dos compradores leen «quedan 5», ambos restan, ambos guardan 4.

Actualización perdida. Con 20 000 personas, miles de veces por minuto.

No bloqueo pesimista: serializaría a todos sobre la misma fila → cambia un problema de corrección por uno de disponibilidad.

Resultado medido

```
20 compradores simultáneos · 4 boletas disponibles  
→ 4 exitosas · 16 rechazadas con 409 · SOBREVENTA: 0
```

1 044 conflictos resueltos durante la prueba de carga. Cero inconsistencias.

El hallazgo más valioso fue un fracaso

Primera implementación: espera exponencial para los conflictos

Configuración	Tasa de error
5 intentos, espera exponencial	30 %
12 intentos, espera exponencial	92 % 
12 intentos, espera corta aleatoria	< 5 %

Subir los reintentos empeoró el resultado. Las esperas superaban el *timeout* del gateway.

Un conflicto de concurrencia no es una caída.

No hay nada recuperándose que necesite tiempo: se resuelve en microsegundos.

El backoff exponencial es correcto para la red y **contraproducente** para bloqueos.

Un patrón mal aplicado es peor que ningún patrón. Solo la medición lo reveló.

Patrón 5 · Cache-Aside + CQRS

Por cada compra hay entre 50 y 200 consultas

- **Cache-Aside** con invalidación por evento → **212 ms → 2 ms (-99 %)**
- **CQRS**: el catálogo mantiene su propia vista de disponibilidad, actualizada **consumiendo eventos**, no consultando a reservas

La decisión difícil: consistencia eventual

Mostrar «quedan 43» cuando quedan 41 **no daña a nadie**.

La venta la valida siempre el almacén autoritativo.

Consistencia fuerte donde el negocio no admite error.

Consistencia eventual donde la exactitud no se justifica.

El detalle que se olvida: la estampida de caché

25 peticiones simultáneas sobre una clave vacía → **1 sola lectura al origen**

Demostración en vivo

Panel de control · <http://localhost:8080>

1. **Cache-Aside** — recargar dos veces: `base-de-datos` → `cache`
2. **Agregación BFF** — una llamada, tres servicios
3. **Compra** — la saga con sus 4 pasos
4. **Idempotencia** — reenviar la misma clave
5. **Tumbar pagos**

— compensación + cortacircuitos en vivo
6. **Recuperación automática** — sin reiniciar nada

Resultados medidos

Escenario	rps	p50	p95	Error
Catálogo (cacheado)	3 739	5 ms	8 ms	0 %
Agregación BFF	1 794	11 ms	14 ms	0 %
Compra completa (saga)	26	408 ms	800 ms	4,5 %
Compra con 30 % de fallos	25	441 ms	850 ms	3,3 %

41 / 41 pruebas automatizadas	24 unitarias + 17 de integración real
9 / 11 RNF verificables cumplidos	Los 2 restantes: declarados como no verificables
0 boletas sobrevendidas	En todos los escenarios
99,9 % de aciertos de caché	Bajo carga sostenida

Lo que NO funciona (y hay que decirlo)

Limitación	Por qué está ahí	Cómo se resuelve
Persistencia en memoria	Es un prototipo académico	PostgreSQL por servicio
Broker propio	Sin dependencias, por reproducibilidad	SQS / Service Bus
Clave de API estática	Fuera del alcance	OAuth 2.0 / OIDC
Contención > 50 escritores	Límite del bloqueo optimista	Particionar el inventario
Gateway con una instancia	Punto único de fallo	2 réplicas en zonas distintas

Dos requisitos NO se verificaron

RNF-03 (100 000 usuarios) y **RNF-05** (99,9 %) exigen carga distribuida y operación real.

Afirmar que se cumplen con esta evidencia sería incorrecto.

Conclusiones

1. La arquitectura se justifica por **atributos de calidad**, no por tecnología.
2. En sistemas distribuidos **el fallo es el caso normal**, no la excepción.
711 ms → 1 ms es la justificación completa del cortacircuitos.
3. La consistencia es **una decisión de diseño**, no un absoluto.
Fuerte en el inventario. Eventual en la disponibilidad mostrada.
4. Los patrones son **vocabulario, no recetas**. Lo que importa es saber cuál, por qué, y **qué se paga por él**.
5. Un patrón mal aplicado **es peor que ningún patrón** (30 % → 92 % de error).
6. La modularidad **se paga con complejidad operativa**. Para una demanda estable, el monolito modular habría sido la respuesta correcta.

Gracias

¿Preguntas?

Repositorio: <https://github.com/ingjvelez17/armonia-arquitectura>

Prototipo desplegado: <https://armonia-gateway.onrender.com>

Juan Esteban Vélez Venegas
Arquitectura de Software · Unidad 1